

ITRN

LICENCIATURA EN INGENIERÍA DE DATOS E INTELIGENCIA ARTIFICIAL

Grupo 2 — Alemania

Pronóstico de consumo eléctrico urbano mediante series temporales

Alejandra Ramírez - 5019273-4

Alvaro Barreto - 5536617-2

Luisa Flores - 5534744-3

22/06/2026

1. Introducción y planteamiento del problema

El proyecto aborda un problema de forecasting aplicado al consumo eléctrico de la zona 1. A partir de registros históricos ordenados temporalmente, se busca anticipar el consumo eléctrico de las próximas 24 horas. La variable temporal utilizada es fecha, mientras que la variable objetivo original es consumo_zona_1, renombrada como “y” durante el modelado para trabajar con una estructura estándar de series temporales.

El objetivo principal fue construir un flujo reproducible de pronóstico con skforecast, incluyendo preparación temporal de los datos, análisis exploratorio, construcción de modelos univariantes, evaluación mediante backtesting, ajuste de hiperparámetros, incorporación de variables exógenas y comparación final de resultados.

Este tipo de problema requiere respetar el orden temporal de las observaciones, ya que no sería correcto mezclar datos futuros con datos pasados durante el entrenamiento o la evaluación. Por ese motivo, la separación entre entrenamiento, validación y test se realizó de forma cronológica.

2. Descripción del dataset

El dataset utilizado contiene 52.416 registros y 7 columnas. Las observaciones originales se encuentran registradas cada 10 minutos, con fechas desde el 2017-01-01 00:00:00 hasta el 2017-12-30 23:50:00. Para el modelado, la serie fue re-muestreada a frecuencia horaria mediante el promedio de las mediciones dentro de cada hora. Luego de esta transformación, el dataset quedó compuesto por 8.736 registros horarios.

Elemento	Detalle
Variable temporal	fecha
Variable objetivo	consumo_zona_1 / y
Frecuencia original	10 minutos
Frecuencia de trabajo	1 hora
Horizonte de predicción	24 pasos horarios
Exógenas	temperatura, humedad, velocidad_viento, flujo_difuso_general, flujo_difuso

En la exploración inicial se detectaron 30 valores faltantes en cada variable numérica. No se observaron duplicados completos ni duplicados por fecha. Luego del re-muestreo horario quedaron 3 valores faltantes por columna, los cuales fueron imputados dentro de cada bloque temporal para evitar fuga de información entre entrenamiento, validación y test.

También se analizaron patrones visuales de la serie, como el comportamiento del consumo durante la primera semana, el consumo promedio por hora del día y el consumo promedio por día de la semana. Estos gráficos permitieron identificar patrones diarios y semanales relevantes para el modelado.

3. Metodología

La metodología se desarrolló respetando el orden temporal de los datos. En primer lugar, la columna fecha fue convertida a formato datetime, luego se ordenaron los registros cronológicamente y se definió la fecha como índice temporal. Posteriormente, los datos

fueron re-muestreados a frecuencia horaria utilizando el promedio de las observaciones de cada hora.

La división temporal utilizada fue la siguiente:

Conjunto	Cantidad de registros	Uso
Entrenamiento	5.592	Ajuste inicial de los modelos
Validación	1.397	Backtesting y selección de modelos
Test	1.747	Evaluación final

La imputación de valores faltantes se realizó por separado en cada conjunto temporal mediante interpolación temporal, forward fill y backward fill. Esta decisión evita que información del futuro sea utilizada para completar valores faltantes del pasado.

Para los modelos se utilizaron rezagos recientes, diarios y semanales de la variable objetivo: [1, 2, 3, 23, 24, 25, 47, 48, 49, 167, 168]

Estos rezagos permiten capturar dependencias inmediatas, patrones diarios cercanos a las 24 horas y patrones semanales cercanos a las 168 horas.

El horizonte de predicción fue de 24 horas y la métrica principal utilizada fue el MAE, ya que permite interpretar el error promedio en las mismas unidades de la variable objetivo.

Como modelo base se utilizó Ridge, comparando estrategia recursiva y estrategia directa. Luego se entrenaron modelos más avanzados con Random Forest y LightGBM, primero de forma univariante y luego incorporando variables exógenas. La evaluación se realizó mediante TimeSeriesFold, backtesting_forecaster y grid_search_forecaster.




Figura 1. Separación temporal del dataset en train, validación y test.

4. Resultados y discusión

El modelo base Ridge permitió comparar estrategias iniciales de forecasting. La estrategia recursiva obtuvo mejores resultados que la estrategia directa. Dentro de esta comparación, la mejor configuración base fue Ridge recursivo con ventana deslizante, alcanzando un MAE de validación de 1212,28.

A partir de ese resultado, los modelos avanzados se evaluaron utilizando estrategia recursiva. La comparación final entre modelos fue la siguiente:

Modelo	Exógenas	MAE validación	MAE test
RandomForest_univariante	No	1221,84	1097,42
LightGBM_univariante	No	1232,77	1137,35
RandomForest_exogenas	Sí	1241,74	1085,57
LightGBM_exogenas	Sí	1238,49	1137,87

En validación, el mejor desempeño correspondió al modelo RandomForest univariante. Sin embargo, en la evaluación final sobre el conjunto de test, el mejor resultado fue obtenido por RandomForest con variables exógenas, con un MAE de 1085,57.

Comparado con el mejor modelo univariante, RandomForest_univariante con MAE test de 1097,42, el modelo con exógenas redujo el error en aproximadamente 11,85 unidades. Esto representa una mejora cercana al 1,08 %. Si bien la mejora es moderada, indica que las variables meteorológicas y de radiación aportan información adicional al patrón histórico del consumo eléctrico.

En el gráfico de predicciones sobre test se observa que el modelo final logra reproducir adecuadamente la estacionalidad diaria y los ciclos generales de consumo. Sin embargo, algunos picos y caídas extremas no se capturan de forma perfecta, lo cual es esperable en un problema de demanda eléctrica con variabilidad horaria.




Figura 2. Valores reales y predicciones en test del modelo final RandomForest con exógenas.

5. Conclusiones

El flujo desarrollado cumple con las etapas principales del proyecto: planteamiento del problema, preparación temporal, análisis exploratorio, modelo base, backtesting, ajuste de hiperparámetros, incorporación de variables exógenas y comparación final de modelos.

La decisión de trabajar con frecuencia horaria permitió reducir el ruido de los registros originales de 10 minutos y facilitar el modelado de patrones diarios y semanales. Además, la separación cronológica de los datos permitió evaluar los modelos de forma coherente con un problema real de forecasting.

El modelo seleccionado fue RandomForest con variables exógenas, ya que obtuvo el menor MAE en el conjunto de test. Luego de la selección, el modelo fue entrenado nuevamente utilizando todo el dataset disponible y guardado como `mejor_modelo_tetuan.joblib`, junto con sus metadatos.

La principal limitación práctica del modelo es que, para predecir el consumo de las próximas 24 horas, se requiere conocer o estimar previamente las variables exógenas futuras, como temperatura, humedad, viento y radiación. Como mejoras futuras, se podrían incorporar pronósticos meteorológicos reales, evaluar otros horizontes de predicción y comparar métricas complementarias como RMSE o MAPE.

6. Referencias

Skforecast. Documentación oficial:

- ForecasterRecursive: https://skforecast.org/latest/user_guides/autoregressive-forecaster.html
- ForecasterDirect: https://skforecast.org/latest/user_guides/direct-multi-step-forecasting.html
- TimeSeriesFold: https://skforecast.org/latest/api/model_selection.html#skforecast.model_selection.TimeSeriesFold
- Backtesting: https://skforecast.org/latest/user_guides/backtesting.html
- Grid Search: https://skforecast.org/latest/user_guides/hyperparameter-tuning-and-lags-selection.html

Scikit-learn. Documentación oficial:

- Ridge Regression: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html
- RandomForestRegressor: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html>

LightGBM. Documentación oficial:

- LightGBM: <https://lightgbm.readthedocs.io/en/latest/>
- LGBMRegressor: <https://lightgbm.readthedocs.io/en/latest/pythonapi/lightgbm.LGBMRegressor.html>